

Proyecto de Inteligencia Artificial

Planificador de rutas de aprendizaje mediante búsqueda A*



Nombre: Abel de la Noval Pérez
Grupo: C-311
Fecha: 14 de junio de 2026

Índice

1. Introducción	2
2. Modelado formal	2
3. Descripción de los datos utilizados	3
4. Diseño del algoritmo de búsqueda	3
5. Rol del modelo de lenguaje en el sistema	4
6. Metodología experimental y resultados	4

1. Introducción

Este proyecto aborda la construcción de un sistema de planificación automática de rutas de aprendizaje a partir de un dominio estructurado de habilidades y cursos con prerequisites. El problema se enmarca dentro de los enfoques clásicos de búsqueda en Inteligencia Artificial, donde se modela un espacio de estados que representa el conjunto de conocimientos adquiridos en cada etapa del proceso de aprendizaje.

El objetivo del sistema consiste en, dado un conjunto de habilidades iniciales y una meta expresada en términos de habilidades objetivo, determinar una secuencia válida de cursos que permita alcanzar dicha meta respetando las restricciones definidas en el dominio. Estas restricciones incluyen dependencias entre habilidades, costes asociados a los cursos y la necesidad de aplicar únicamente acciones válidas en cada estado.

Para resolver este problema se implementa un modelo basado en representación STRIPS del dominio, junto con un algoritmo de búsqueda informada (A^*) que explora el espacio de estados de manera eficiente. Adicionalmente, se incorpora un módulo de interpretación de objetivos en lenguaje natural, que traduce la intención del usuario a un conjunto formal de habilidades dentro del catálogo definido.

El sistema integra así tres componentes principales: la formalización del dominio, la traducción del objetivo y la planificación de la ruta óptima, garantizando la coherencia entre la entrada del usuario, el modelo de habilidades y la solución generada.

2. Modelado formal

El problema de planificación de rutas de aprendizaje se modela como un problema de búsqueda en un espacio de estados tipo STRIPS.

Un estado representa el conjunto de habilidades que un estudiante ha adquirido en un momento dado. Formalmente, un estado S se define como un subconjunto del conjunto total de habilidades disponibles en el dominio:

$$S \subseteq Skills$$

El estado inicial S_0 corresponde al conjunto de habilidades proporcionadas por el usuario al inicio del proceso.

El objetivo del sistema se define como un conjunto de habilidades meta:

$$G = \{g_1, g_2, \dots, g_n\}$$

Un estado es considerado solución si satisface la condición:

$$G \subseteq S$$

Las transiciones entre estados se realizan mediante la aplicación de acciones, donde cada acción representa un curso del catálogo. Cada acción se define como una tupla:

$$a = (pre(a), add(a), cost(a))$$

donde $pre(a)$ es el conjunto de habilidades requeridas, $add(a)$ es el conjunto de habilidades adquiridas al completar el curso y $cost(a)$ es el coste asociado.

Una acción es aplicable en un estado si $pre(a) \subseteq S$, y su aplicación genera un nuevo estado:

$$S' = S \cup \text{add}(a)$$

El problema se interpreta como un grafo dirigido ponderado donde los nodos representan estados y las aristas representan transiciones entre ellos mediante cursos. El objetivo consiste en encontrar un camino de coste mínimo desde el estado inicial hasta cualquier estado que satisfaga la condición de objetivo.

Para la resolución del problema se emplea un algoritmo de búsqueda A^* , que utiliza una función heurística admisible para estimar el coste restante hacia el objetivo.

3. Descripción de los datos utilizados

El sistema se apoya en un conjunto de datos sintético que define el dominio de planificación. Este dominio está compuesto por dos elementos principales: un catálogo de habilidades y un catálogo de cursos.

Las habilidades representan unidades atómicas de conocimiento dentro del sistema, mientras que los cursos representan acciones que permiten adquirir una o varias habilidades, siempre bajo restricciones de prerrequisitos y con un coste asociado.

Los datos han sido diseñados de forma manual con el objetivo de construir un entorno controlado que permita evaluar el comportamiento de los algoritmos de búsqueda en diferentes escenarios. En particular, el dominio incluye rutas alternativas, dependencias entre habilidades y cursos con distintos niveles de coste, lo que permite observar cómo el sistema selecciona diferentes soluciones dependiendo de la estructura del grafo de estados.

Este diseño sintético no busca representar un caso real específico, sino proporcionar un entorno suficientemente complejo para validar el funcionamiento del modelo de planificación, la heurística implementada y el algoritmo de búsqueda A^* .

El uso de datos artificiales permite además controlar la complejidad del problema y garantizar la existencia de múltiples rutas válidas, lo cual es fundamental para evaluar la capacidad del sistema de encontrar soluciones óptimas bajo diferentes configuraciones del dominio.

4. Diseño del algoritmo de búsqueda

Para resolver el problema de planificación se ha implementado el algoritmo de búsqueda A^* , un algoritmo de búsqueda informada que permite encontrar caminos de coste mínimo en un espacio de estados ponderado.

El algoritmo mantiene una estructura de prioridad (open list) donde cada estado se ordena según una función de evaluación definida como:

$$f(n) = g(n) + h(n)$$

donde $g(n)$ representa el coste acumulado desde el estado inicial hasta el nodo actual, y $h(n)$ representa una estimación del coste restante hasta alcanzar el objetivo.

En este sistema, el valor de $g(n)$ corresponde a la suma de los costes de los cursos aplicados a lo largo de la ruta. La función heurística $h(n)$ está basada en una estimación relajada del coste restante necesario para alcanzar el conjunto de habilidades objetivo, considerando las dependencias entre habilidades y cursos del dominio.

El algoritmo expande iterativamente el nodo con menor valor de $f(n)$, generando sus sucesores mediante la aplicación de cursos válidos según sus prerrequisitos. Cada transición entre estados corresponde a la ejecución de un curso, lo que modifica el conjunto de habilidades disponibles en el estado resultante.

5. Rol del modelo de lenguaje en el sistema

El sistema integra un modelo de lenguaje (LLM) como componente inicial del flujo de planificación, cuya función principal es interpretar la intención expresada por el usuario en lenguaje natural y traducirla a una representación formal compatible con el dominio del sistema.

Dado un objetivo expresado por el usuario, el modelo de lenguaje analiza el contenido semántico de la entrada y extrae las habilidades relevantes que mejor representan dicho objetivo dentro del catálogo definido. Esta salida se estructura como un conjunto de identificadores de habilidades (*target skills*), los cuales constituyen la entrada formal al sistema de planificación.

Por ejemplo, ante una entrada como: "*Quiero aprender machine learning*", el modelo no genera un plan ni una secuencia de acciones, sino que identifica las habilidades relevantes dentro del dominio, como:

$$\{skill_{10}\}$$

El modelo está restringido explícitamente para no inferir dependencias, no generar rutas y no realizar planificación. Su función se limita únicamente a la traducción semántica entre lenguaje natural y el espacio de habilidades definido en el catálogo.

La salida del modelo es posteriormente validada mediante un módulo de verificación, que comprueba que las habilidades generadas existen en el dominio y que cumplen las restricciones del sistema. En caso de ser válidas, estas habilidades se utilizan como objetivo formal del problema de planificación.

Este diseño permite separar claramente la interpretación del lenguaje natural del proceso de búsqueda, delegando la planificación a algoritmos clásicos de Inteligencia Artificial (A^*), mientras que el modelo de lenguaje actúa únicamente como interfaz de interpretación semántica.

6. Metodología experimental y resultados

Se definió un conjunto de casos de prueba con el objetivo de evaluar el comportamiento del sistema de planificación de rutas de aprendizaje basado en búsqueda A^* .

El análisis se centra en la capacidad del algoritmo para seleccionar rutas óptimas en presencia de múltiples alternativas, así como su comportamiento ante cambios en los costes de los cursos y ante entradas fuera del dominio del sistema.

Casos de prueba

Caso 1: Machine Learning como objetivo

Descripción del caso de prueba

Este caso evalúa la capacidad del sistema para interpretar un objetivo expresado en lenguaje natural y transformarlo en una secuencia óptima de habilidades dentro del catálogo definido. En particular, se analiza el objetivo “I want to learn machine learning”, partiendo del estado inicial correspondiente a la habilidad *skill_01 (Python fundamentals)*.

El sistema debe determinar la habilidad objetivo asociada y encontrar la ruta de menor coste para alcanzarla mediante el uso de cursos disponibles.

Interpretación del objetivo

El módulo basado en LLM traduce la entrada al siguiente objetivo formal:

- Skill objetivo: *skill_10 (Supervised Machine Learning)*

Rutas posibles evaluadas

A partir del estado inicial, el sistema explora el espacio de estados mediante el algoritmo de búsqueda, identificando dos rutas principales:

Ruta 1: Secuencia modular de cursos

Esta ruta representa la progresión estándar mediante cursos individuales encadenados:

- $\text{skill_01} \rightarrow \text{skill_03} \rightarrow \text{skill_08} \rightarrow \text{skill_09} \rightarrow \text{skill_10}$
- Coste total: 14
- Número de cursos: 4

Ruta 2: Uso de bootcamp intensivo

Esta alternativa utiliza un curso intensivo que proporciona múltiples habilidades intermedias:

- $\text{skill_08}, \text{skill_09}, \text{skill_10}, \text{skill_11}, \text{skill_12}$

Adicionalmente, se requiere completar *skill_03* mediante un curso independiente.

- Coste bootcamp: 18
- Curso adicional: 2
- Coste total: 20

Resultado del caso

El sistema selecciona la Ruta 1 (secuencia modular), ya que presenta el menor coste total:

- Ruta seleccionada: Secuencia modular
- Coste final: 14

Este resultado valida que el sistema prioriza la optimización del coste total sobre la longitud de la ruta o el uso de cursos intensivos.

Caso 2: Optimización de rutas hacia Data Engineer

Descripción del caso de prueba

En este caso se evalúa la capacidad del sistema para encontrar la ruta óptima hacia la habilidad objetivo *skill_21* (*Data Engineer*).

Interpretación del objetivo

El módulo LLM traduce la entrada del usuario en el objetivo formal:

- Skill objetivo: *skill_21* (*Data Engineer*)

Rutas posibles evaluadas

El algoritmo identifica dos estrategias principales:

Ruta 1: Progresión lineal de prerequisites

Esta ruta sigue la cadena completa de dependencias entre habilidades:

- $\text{skill_1} \rightarrow \text{skill_8} \rightarrow \text{skill_2} \rightarrow \text{skill_18} \rightarrow \text{skill_19} \rightarrow \text{skill_20} \rightarrow \text{skill_21}$

El coste acumulado aproximado de esta ruta es:

- Coste total: 24
- Número de cursos: elevado

Ruta 2: Bootcamp de Data Engineering

Esta alternativa utiliza un curso intensivo que proporciona directamente las habilidades intermedias clave:

- Curso: Data Engineering Bootcamp
- Skills obtenidas: *skill_18*, *skill_19*, *skill_20*

Posteriormente, se completa la habilidad final:

- $\text{skill_20} \rightarrow \text{skill_21}$
- Coste bootcamp: 10
- Coste adicional: 4
- Coste total: 14

Resultado del caso

El sistema selecciona la Ruta 2 (Bootcamp de Data Engineering), ya que presenta el menor coste total:

- Ruta seleccionada: Bootcamp + cierre en *skill_21*
- Coste final: 14
- Número de pasos: menor que la ruta lineal

Este resultado demuestra que el sistema prioriza la optimización del coste total en un caso de Bootcamp mas óptimo.

Caso 3: Objetivo fuera del dominio del sistema

Descripción del caso de prueba

En este caso se evalúa el comportamiento del sistema cuando la entrada del usuario no corresponde a ninguna habilidad existente dentro del catálogo definido.

El objetivo es verificar que el sistema no genera habilidades ficticias ni realiza asignaciones incorrectas, manteniendo consistencia con el conjunto de datos disponible.

Entrada del sistema

- “I want to become an astronaut”

Interpretación del LLM

El módulo basado en lenguaje natural intenta mapear la entrada a una habilidad del catálogo. Sin embargo, no existe ninguna correspondencia semántica válida con las habilidades definidas en el sistema.

Evaluación del sistema

Al no encontrar coincidencias en el catálogo de habilidades, el sistema determina que el objetivo no es alcanzable dentro del dominio actual del problema.

Resultado del caso

- Skill objetivo: ninguna asignación válida
- Respuesta del sistema: objetivo no disponible en el catálogo

Este resultado confirma que el sistema es consistente con las restricciones del dominio y no genera habilidades fuera del conjunto definido.

Limitaciones y posibles mejoras

Limitaciones del sistema

A pesar de que el sistema implementa correctamente un algoritmo de búsqueda informada (A^*) junto con una heurística admisible basada en habilidades faltantes, presenta ciertas limitaciones inherentes al diseño del modelo de representación:

- **Modelo de coste simplificado:** actualmente el coste de cada curso se representa como un único valor escalar. Esto no permite capturar factores más realistas como duración, dificultad o carga de estudio.
- **Heurística basada únicamente en cantidad de habilidades:** la función heurística estima el coste restante considerando únicamente el número de habilidades faltantes, lo cual puede no reflejar con precisión la complejidad real de las dependencias.
- **Dependencias estáticas:** el modelo asume que las relaciones entre cursos y habilidades son fijas, sin considerar variaciones o rutas dinámicas alternativas más complejas.

- **Dependencia del catálogo definido:** el sistema solo puede operar dentro del conjunto de habilidades y cursos predefinidos, sin capacidad de expansión automática del dominio.

Posibles mejoras

A partir de las limitaciones anteriores, se identifican varias posibles extensiones del sistema:

- **Heurísticas multi-criterio:** extender la función heurística para considerar múltiples factores simultáneamente, como coste económico, duración del curso y dificultad percibida, en lugar de un único valor numérico.
- **Modelado más rico de los cursos:** incorporar atributos adicionales en los cursos, tales como tiempo estimado de finalización, nivel de dificultad o impacto en habilidades avanzadas.
- **Mejoras en la representación del estado:** incluir información contextual adicional en el estado, permitiendo una búsqueda más informada y flexible.
- **Generalización del modelo LLM:** mejorar el mapeo entre lenguaje natural y habilidades mediante técnicas más avanzadas de comprensión semántica o embeddings, reduciendo la dependencia de coincidencias directas con el catálogo.

En conjunto, estas mejoras permitirían evolucionar el sistema hacia un planificador de rutas de aprendizaje más realista y adaptable a distintos criterios de optimización.